

Documento de Requisitos Projeto Tutor Responsável: Patricia Pereira Martins – Time de Requisitos e Testes **Data:** Abril/2026 **Versão:** 1.0

EP-09 — Gestão do Modelo de IA

Descrição: Permite ao administrador selecionar e ativar o modelo de linguagem que será utilizado pela plataforma. Os modelos disponíveis são obtidos dinamicamente da biblioteca oficial do Ollama via scraping. O sistema consulta a API local do Ollama para identificar quais modelos já estão instalados, realiza o download dos ausentes e persiste o modelo ativo em banco de dados. Todas as requisições de geração de texto utilizam o modelo ativo configurado.

Personas: Administrador

Protótipo: [Design System](#)

Protótipo Sprint 2 — Gestão de Modelo de IA: [Catálogo de LLM](#)

US-38 — Seleção e ativação de modelo de IA via Ollama

Como administrador, **quero** selecionar qual modelo de linguagem será utilizado pela plataforma a partir de uma lista atualizada da biblioteca do Ollama, **para que** eu possa controlar qual IA processa as perguntas dos alunos e garantir que o modelo esteja disponível localmente antes de ser ativado.

Regras de Negócio

- A lista de modelos disponíveis é obtida por scraping da página oficial da biblioteca do Ollama — sempre atualizada dinamicamente.
- O sistema consulta a API local do Ollama para identificar quais modelos já estão instalados.
- A lista exibe visualmente dois estados: **Instalado** (pronto para ativar) e **Disponível para download**.
- Ao selecionar um modelo não instalado, o sistema realiza o pull via API do Ollama antes de ativá-lo.
- Durante o download, o sistema exibe o progresso em tempo real (percentual ou barra de progresso).
- Ao clicar em **"Ativar"** de um modelo já instalado, o sistema exibe um modal de confirmação antes de efetuar a troca, evitando ativações acidentais.
- Após instalação (ou se já instalado e confirmado pelo administrador), o modelo é definido como **modelo ativo**.
- O modelo ativo é persistido em banco de dados e passa a ser utilizado em todas as requisições de geração de texto da plataforma.
- Apenas um modelo pode estar ativo por vez; a troca substitui o anterior sem reprocessar materiais já indexados.
- A configuração é global — aplica-se a todas as matérias da plataforma.

Regras de Validação

- Se a lista de modelos não puder ser obtida (scraping falha), exibir: *"Não foi possível carregar a lista de modelos. Verifique a conexão e tente novamente."*

- Se a API local do Ollama não estiver acessível, exibir: *"Serviço Ollama não encontrado. Verifique se o Ollama está em execução."*
- Se o download falhar, exibir: *"Falha ao baixar o modelo [nome]. Verifique a conexão e tente novamente."* O modelo anterior permanece ativo.
- Não é permitido ativar um modelo que não está instalado sem concluir o download.

Regras de Interface

- A tela exibe a lista de modelos com: nome, tamanho estimado e estado (Instalado / Disponível para download).
- Modelos instalados possuem botão **"Ativar"**. Modelos não instalados possuem botão **"Fazer Download"**.
- O modelo atualmente ativo é destacado visualmente (badge ou indicador "Ativo").
- Ao clicar em **"Ativar"** de um modelo instalado, o sistema exibe um modal de confirmação com:
 - Título: *"Ativar o modelo [nome]?"*
 - Texto descritivo: *"O [modelo atual] deixará de atender novas mensagens e o [novo modelo] passará a ser o modelo ativo. As conversas em andamento seguem normalmente com o modelo atual."*
 - Ação primária (accent): botão *"Ativar [nome]"*
 - Ação secundária (outlined): botão *"Cancelar"*
- Durante o download, o botão é substituído por uma barra de progresso com opção de cancelar.
- Após ativação bem-sucedida, o sistema exibe confirmação: *"Modelo [nome] ativado com sucesso."*

Requisitos Não Funcionais

- O progresso do download deve ser atualizado em tempo real (polling ou streaming via SSE).
- A troca de modelo ativo não deve interromper conversas em andamento — sessões ativas concluem com o modelo anterior.
- A lista de modelos disponíveis deve ser obtida com cache máximo de 1 hora para evitar scraping excessivo da página do Ollama.

Pré-requisitos

- O administrador deve estar autenticado.
- O serviço Ollama deve estar em execução e acessível pelo backend.

Critérios de Aceitação

- ☐ A lista de modelos é carregada dinamicamente da biblioteca oficial do Ollama.
- ☐ A lista indica visualmente quais modelos estão instalados e quais precisam ser baixados.
- ☐ Administrador consegue ativar um modelo já instalado após confirmar no modal de confirmação.
- ☐ Ao clicar em "Ativar" de um modelo instalado, o sistema exibe o modal com título, descrição contextual e botões "Cancelar" e "Ativar [nome]".
- ☐ Cancelar no modal mantém o modelo anterior ativo e fecha o modal sem alterações.
- ☐ Administrador consegue baixar e ativar um modelo não instalado; o progresso é exibido em tempo real.
- ☐ Falha no scraping exibe mensagem explicativa sem travar a tela.
- ☐ Falha no download mantém o modelo anterior ativo e exibe mensagem explicativa.
- ☐ O modelo ativo é salvo em banco de dados e persiste após reinicialização do servidor.

- ☐ Todas as requisições de geração de texto passam a usar o modelo ativo imediatamente após a troca.
- ☐ A troca de modelo não reprocessa materiais já indexados.
- ☐ Sessões de chat em andamento no momento da troca concluem normalmente com o modelo anterior.